

PUCRS — Computação Paralela 2026/2
Exercícios de Fixação — Aulas 02 e 03

Arquiteturas Paralelas e Métricas de Desempenho

Parte 1 — Evolução das Arquiteturas e Conceitos

- 1) Até meados dos anos 2000, o desempenho dos processadores crescia principalmente pelo aumento da frequência de *clock*. A partir de então a indústria passou a replicar núcleos no mesmo chip (*multicore*), embora a Lei de Moore, a duplicação do número de transistores a cada 18–24 meses, tenha continuado válida por mais alguns anos.
- Por que o aumento de frequência deixou de ser a estratégia principal?
 - Para onde foram os transistores adicionais? Cite dois destinos.
 - Qual é a consequência dessa mudança para quem escreve software de alto desempenho?

Parte 2 — Classificação de Flynn e Modelos de Memória

- 2) Com base na classificação de Flynn, marque a alternativa correta:
- Em SISD, múltiplas instruções operam sobre múltiplos fluxos de dados, como em supercomputadores.
 - SIMD é representado por CPUs que executam vários programas diferentes em paralelo.
 - MIMD é a classe dos processadores *multicore* e dos clusters, programados respectivamente com OpenMP e MPI.
 - MISD é a arquitetura das GPUs modernas, que aplicam muitas instruções sobre um único fluxo de dados.
 - Uma aplicação MPI em que todos os processos executam o mesmo binário é classificada como SIMD, já que há um único programa.
- 3) Sobre os mecanismos de acesso à memória e de coerência de cache, assinale a alternativa correta:
- Em arquiteturas UMA, a memória é distribuída entre os processadores e cada um acessa apenas a sua parte local, com menor latência.
 - Em sistemas NUMA, todos os processadores acessam a memória com a mesma latência, independentemente de onde o dado foi alocado.
 - Em arquiteturas CC-NUMA, a coerência de cache é garantida por hardware, mesmo que o custo de acesso à memória seja variável.
 - Em arquiteturas NORMA, um processador acessa a memória de outro nó por *load* e *store*, sem necessidade de troca de mensagens.
 - COMA é o modelo dos clusters, no qual cada nó possui memória, armazenamento e sistema operacional próprios.

Parte 3 — Consequências da Arquitetura no Código

- 4) Cada nodo do cluster do LAD possui 2 processadores de 8 núcleos, com *Hyper-Threading* (SMT) habilitado e memória compartilhada dentro do nodo; os nodos são interligados por uma rede InfiniBand. Você vai paralelizar uma aplicação que aplica repetidamente um filtro de suavização a uma imagem grande, armazenada como uma matriz 2D: cada pixel do resultado é calculado a partir dos seus vizinhos, o padrão que chamamos de *estêncil*.

Determine V ou F para cada afirmativa. **Justifique as falsas.**

- () Como o sistema operacional enxerga 32 processadores lógicos por nodo, executar a aplicação com 32 *threads* OpenMP entrega o dobro do desempenho obtido com 16 *threads*.
- () Inicializar a imagem inteira em um laço sequencial e depois processá-la em um laço paralelo não afeta o desempenho, pois dentro do nodo o espaço de endereçamento é único e todas as *threads* enxergam os mesmos endereços.
- () Duas *threads* que escrevem em posições distintas de um mesmo vetor nunca interferem uma no desempenho da outra, já que não há condição de corrida sobre os dados.
- () Ao distribuir a aplicação por vários nodos, a comunicação passa a ser explícita (*send/receive*); como a latência é paga por mensagem, agrupar as bordas em poucas mensagens grandes tende a ser mais rápido do que enviar muitas mensagens pequenas.

Parte 4 — Métricas de Desempenho

- 5) Uma aplicação de estêncil 2D foi medida em um único nodo, com a malha fixa. O tempo do melhor algoritmo sequencial é $T_1 = 240$ s. A tabela traz a mediana de 10 execuções:

p	1	2	4	8	16
T_p (s)	240	125	68	41	38
SU_p					
E_p					

- Complete a tabela com o *speed-up* e a eficiência (2 casas decimais).
 - Um *profiling* indica fração sequencial $s = 0,05$. Calcule o teto previsto pela Lei de Amdahl para $p = 16$ e para $p \rightarrow \infty$. Compare com o *speed-up* medido e explique a diferença.
 - Se o problema crescesse proporcionalmente a p , qual seria o *speed-up* escalado previsto pela Lei de Gustafson com $s = 0,05$ e $p = 16$?
- 6) Um aluno entregou o seguinte relato de desempenho:
- “Compilei a versão paralela sem otimização e medi uma execução com 1 thread ($T_1 = 610$ s) e uma execução com 8 threads ($T_8 = 65$ s), obtendo *speed-up* de 9,4. Super-linear! Como ficou acima de 8, concluí que o programa escala perfeitamente e que com 64 threads o *speed-up* seria de aproximadamente 75. Para o teste com 8 threads ter mais trabalho, aumentei a malha de 4096^2 para 8192^2 .”

- Aponte **quatro** erros de metodologia no relato e explique o efeito de cada um sobre os números apresentados.
- O *speed-up* superlinear tem alguma causa legítima? Qual?
- Para responder à pergunta “quão rápido resolvo este problema?”, o experimento correto é um **teste de escalabilidade forte**. Descreva como ele deveria ter sido conduzido.